

Desafio Ambev

André Ribeiro de Brito
andrerb_1992@hotmail.com

Abril 2022

1 Introdução

O cérebro artificial tem a capacidade de memorizar, observar e explorar situações para aprender fatos, de modo a aprender, classificar e organizar um conhecimento novo, em outras palavras, podemos considerar como atividades relacionadas ao aprendizado científico por máquina. Assim, a capacidade que uma máquina destinada ao processamento de dados, ou seja, um computador, tem como habilidade de melhorar e classificar o desempenho de um objeto com base na realização de alguma tarefa baseada na experiência desenvolvida, o que consideramos uma subárea da inteligência artificial (IA) chamada de reconhecimento de padrões, do inglês Pattern Recognition.

O advento da Inteligência Artificial (IA) sendo aplicadas às mais diversas segmentos da ciência, trouxe consigo a necessidade de utilizar técnicas computacionais da área do processamento digital de imagens, a fim de estabelecer novos métodos que realizasse melhoria no processo de pré-processamento e processamento, reconhecimento, classificação e recuperação de informação.

Nesse contexto, o Processamento Digital de Imagens (PDI) teve sua primeira aplicação no ano de 1920, quando imagens digitalizadas de jornais ingleses, foram transmitidas por meio de um cabo submarino de Londres para Nova Iorque, reduzindo o tempo de transporte exigido de mais de uma semana para menos de três horas. O equipamento utilizado para fazer essa transmissão, travessavam o oceano Atlântico, codificava as imagens em Londres e transmitia para Nova Iorque, na qual era reconstruída por meio de um terminal receptor [Gonzales and Woods, 2001]. Desde então, as técnicas de PDI vêm sendo aprimorada com o desenvolvimento de novas técnicas e difundida em diversos segmentos.

De acordo com Gonzalez e Woods, as técnicas do processamento de imagens são compostas pelas etapas de aquisição de imagens, pré-processamento, segmentação, pós-processamento, reconhecimento de padrões e classificação [Gonzalez

and Woods, 2007]. Porém, especificamente neste desafio de pesquisa, serão apresentadas as etapas de aquisição, balanceamento de dados, reconhecimento de padrões e classificação com o intuito de mostrar como o aprendizado de métodos supervisionados a partir de imagens digitais pode se tornar uma tarefa aplicada de forma automática.

Em anos recentes, alguns pesquisadores dedicam-se a aprimorar a capacidade de um classificador e o seu poder em classificar imagens com outros modelos, como, por exemplo redes neurais. O exemplo é a rede neural supervisionada Perceptron Multicamadas, utilizada para classificar imagens digitais. De acordo com Haykin e Simon, a rede neural Perceptron Multicamadas baseia-se em uma rede neural humana devido ao fato de que possuem características semelhantes, onde consiste em um conjunto de unidades sensoriais (nós fontes) que constituem a camada de entrada, uma ou mais camadas ocultas (ou intermediárias) de nós computacionais (neurônios) e uma camada de saída de nós computacionais (neurônios) [Haykin and Network, 2004].

Neste contexto, o objetivo deste desafio de pesquisa visa a aplicação de diferentes métodos para a classificação de imagens digitais. Tais abordagens propõem a inclusão de técnicas undersampling e classificadores supervisionados. Nesse sentido, este desafio tem potencial para contribuir com o uso destes classificadores, de forma que, os métodos propostos poderão ser utilizados em uma gama de aplicações envolvendo processamento de imagens e aprendizado de máquina (*Machine Learning*).

Este desafio de pesquisa está estruturado de forma que, o Capítulo 1 tratou da introdução da pesquisa. No Capítulo 2, será descrito o desenvolvimento dos métodos de aprendizado de máquina para classificação de imagens tomográficas. No Capítulo 3, será apresentado a forma de análise dos resultados dos métodos: 1) KNN; 2) SVM Linear; 3) SVM Polinomial; 4) Bayesiano Quadratic; 5) Nearest Mean Classifier; 6) Regressão logística; 7) Perceptron Multicamadas. Por fim, no Capítulo 4, será apresentado a conclusão dos experimentos com resultados obtidos.

2 Metodologia

Na área do processamento de imagens, a etapa de balanceamento de dados, o problema de balancear dados de forma automática e aleatória não é uma tarefa trivial, uma vez que a remoção das imagens digitais podem conter informação importantes para etapas futuras. Nesse contexto, há uma necessidade de se aplicar métodos de balanceamento que visa remover uma certa quantidade de informação em diferentes classes para que haja uma igualdade entre os dados. Sendo assim, o uso do método under sample é uma técnica poderosa para redução de dados que

utiliza a noção de remover uma quantidade de dados em diferentes classes com base na classe de menor quantidade [Lauer, 1999].

As imagens utilizadas para o desenvolvimento deste desafio compõem um banco de imagens digitais referente a rótulos de cervejas fabricadas pela empresa. Cada rótulo pertence a um tipo de cerveja, sendo elas: cerveja Beck's, cerveja Brahma, cerveja BudWeiser, cerveja Corona e cerveja Skol.

Em uma outra vertente, são os métodos de classificação supervisionada, considerado uma abordagem padrão aplicada para classificar dados. Nesse contexto, ao lidar com dados irreconhecíveis, os classificadores supervisionados tem como principal objetivo reconhecer diferentes tipos de dados, a partir de um conhecimento prévio. Ou seja, uma análise prévia com uma certa quantidade de dados, levam ao classificador a decisão de qual rótulo uma determinada classe o pertence. Nesse caso, dado um conjunto de amostras/vetores e um conjunto de rótulos, um classificador prediz a qual classe uma determinada amostra pertence.

O aprendizado supervisionado é de conhecimento do sistema assim como a existência de um conjunto de objetos treinados e pré classificados, de modo que cada objeto tenha uma classe definida e sirva como modelo para classificar os demais objetos [Hart et al., 2000, Costa and Cesar Jr, 2000].

Neste contexto, os métodos de classificação supervisionada utilizados neste desafio, foram: KNN, SVM Linear, SVM Polinomial, Bayesiano Quadratic, Nearest Mean Classifier, Regressão logística e Perceptron Multicamadas.

3 Resultados

Os resultados da classificação automática das imagens digitais foram analisados de forma quantitativa, sendo dividida a base de dados de forma 70% treinamento e 30% teste. Neste caso, o objetivo da análise quantitativa é comparar os métodos existentes na literatura em relação aos demais, como: 1) KNN; 2) SVM Linear; 3) SVM Polinomial; 4) Bayesiano Quadratic; 5) Nearest Mean Classifier; 6) Regressão logística; 7) Perceptron Multicamadas.

Os comandos e funções utilizadas em todo processamento deste trabalho, trata-se de funções prontas, criadas pela própria biblioteca. Neste caso, utilizamos as seguintes funções:

- `make_pipeline`: biblioteca do Sklearn, utilizado para construção um pipeline a partir dos estimadores fornecidos.
- `KNeighborsClassifier`: biblioteca do Sklearn, utilizado para o método de classificação KNN.
- `LinearSVC`: biblioteca do Sklearn, utilizado para o método de classificação SVM Linear.

- svm.SVC: biblioteca do Sklearn, utilizado para o método de classificação SVM Polinomial.
- QuadraticDiscriminantAnalysis: biblioteca do Sklearn, utilizado para o método de classificação Bayesiano Quadrático.
- NearestCentroid: biblioteca do Sklearn, utilizado para o método de classificação Nearest Mean Classifier.
- LogisticRegression: biblioteca do Sklearn, utilizado para o método de classificação Regressão logística.
- MLPClassifier: biblioteca do Sklearn, utilizado para o método de classificação Perceptron Multicamadas.
- cluster.KMeans: biblioteca do Sklearn, utilizado para o método de clusterização K-Means.
- score: biblioteca do Sklearn, utilizado para obter o valor de acurácia dos métodos.

A tabela abaixo, mostra os resultados obtidos com os diferentes métodos aplicados.

Resultados	
Método	Acurácia
KNN	37%
SVM Linear	36%
SVM Polinomial	24%
Bayesiano Quadratic	20%
Nearest Mean Classifier	26%
Regressão logística	34%
Perceptron Multicamadas	26%

Sendo assim, não houve uma melhora acima de 50% de acurácia dos métodos de classificação.

4 Conclusão

Neste trabalho foi feito uma análise sobre os métodos classificação supervisionada existentes na literatura. Desta forma, sua validação foi estabelecida a partir da estruturação de bancos de imagens.

Para o desenvolvimento dos experimentos, foram realizadas análises e comparação dos diferentes métodos de classificação supervisionada, considerando um percentual de 30% da base de dados para teste e 70% para o treinamento. Porém, foram analisados somente o nível de acurácia somente das técnicas classificação supervisionadas.

Como contribuição para trabalhos futuros, o uso de algoritmo de aprendizado de máquina altamente computacionais com configuração intensiva de hardware, para que haja o reconhecimento em tempo real conforme [Mazzia et al., 2020]

Link para o github: <https://github.com/andrerb1992/Desafio>

Referências

- [Costa and Cesar Jr, 2000] Costa, L. d. F. D. and Cesar Jr, R. M. (2000). *Shape analysis and classification: theory and practice*. CRC Press, Inc.
- [Gonzales and Woods, 2001] Gonzales, R. C. and Woods, R. E. (2001). Digital image processing (2rd edition).
- [Gonzalez and Woods, 2007] Gonzalez, R. C. and Woods, R. E. (2007). *Digital Image Processing (3rd Edition)*.
- [Hart et al., 2000] Hart, P. E., Stork, D. G., and Duda, R. O. (2000). *Pattern classification*. Wiley Hoboken.
- [Haykin and Network, 2004] Haykin, S. and Network, N. (2004). A comprehensive foundation. *Neural networks*, 2(2004):41.
- [Lauer, 1999] Lauer, T. R. (1999). Combining undersampled dithered images. *Publications of the Astronomical Society of the Pacific*, 111(756):227.
- [Mazzia et al., 2020] Mazzia, V., Khaliq, A., Salvetti, F., and Chiaberge, M. (2020). Real-time apple detection system using embedded systems with hardware accelerators: An edge ai application. *IEEE Access*, 8:9102–9114.